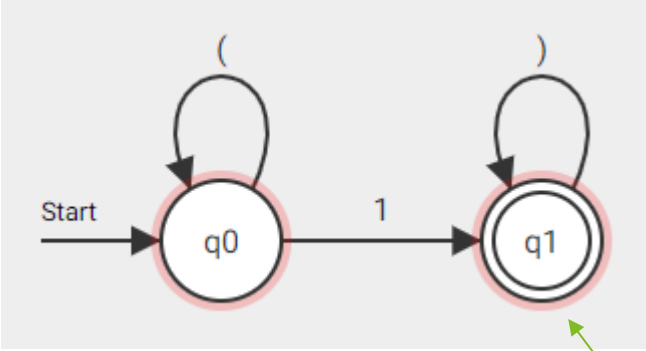
Agenda

1.	Einleitung	2
2.	Grundlagen	19
3.	Programmiersprachen	31
4.	Automaten	45
5.	**Grammatiken**	**109**
6.	Syntaxanalyse	150

Mächtigkeit von regulären Ausdrücken und endlichen Automaten

- In Programmiersprachen kommen oft „Klammerpaare“ vor. Dabei muss die Anzahl der öffnenden und der schließenden Klammern gleich sein.
- Beispiel: ((1)), nicht aber (((1) oder 1))
- 1. Aufgabe: Erstellen Sie einen regulären Ausdruck, der diese Sprache erkennt!
- 2. Aufgabe: Warum kann der u.a. Automat diese Sprache nicht exakt erkennen?



Kommt der DEA in diesen Zustand, „weiß“ er nur, dass er in q_1 ist, aber nicht mehr! Schon gar nicht, wie viele öffnende Klammern er gelesen hat.

Mächtigkeit von regulären Ausdrücken und endlichen Automaten

Offensichtlich reichen endliche Automaten und reguläre Ausdrücke nicht aus, um die in Programmiersprachen üblichen Konstrukte zu beschreiben.



Wir brauchen:

a) Einen flexibleren Mechanismus als reguläre Ausdrücke → Grammatiken

b) Einen Automaten, der mehr Speicher hat. → Kellerautomaten

Chomsky-Hierarchie



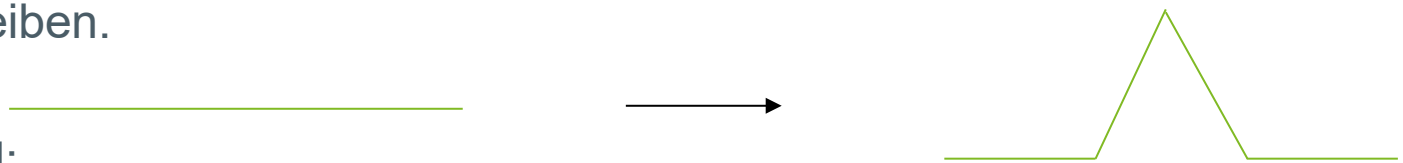
- Noam Chomsky erfand 1956 die Theorie der formalen Grammatiken, die formale Sprachen erzeugen.
- Als Linguist lag sein Fokus auf der Erzeugung von Sprachen, aber man kann Grammatiken auch zur Erkennung von Sprachen nutzen!

Ein Ausflug in die Biologie



Aristid Lindenmayer (*1925-1989), ungarischer Biologe

Lindenmayer beschrieb die Entwicklung biologischer Strukturen durch Systeme (L-Systeme), die mit Regeln eine Zellteilung beschreiben.



Beispiel:

Alphabet + Startzustand (Axiom) + Produktionsregeln

Regeln werden parallel auf eine Generation angewendet,





Kontextfreie Grammatiken

Definition: Eine **kontextfreie Grammatik** G ist ein Vier-Tupel (N, T, P, S) :

- N ist eine endliche Menge von Nichtterminalsymbolen, („Variablen“)
- T ist ein Alphabet („Terminalsymbole“), $N \cap T = \emptyset$
- P ist eine Menge von Produktionsregeln $X \rightarrow \alpha$, wobei $X \in N, \alpha \in (N \cup T)^*$.
- $S \in N$ ist das Startsymbol („Axiom“)

„Kontextfrei“ heißt, dass das Nichtterminalsymbol auf der linken Seite der Produktionsregel immer „alleine“ steht und nicht in einem „Kontext“.

Im Gegensatz zu Lindenmayer-Systemen können nur Variablen ersetzt werden und zwar immer genau eine.

Beispiel

$G = (N, T, P, S)$, wobei

$$T = \{ a, b, c \}$$

$$N = \{ S, A, B \}$$

$$P = \{ S \rightarrow AB, A \rightarrow aA, A \rightarrow \epsilon, B \rightarrow bBb, B \rightarrow c \}$$

Aufgabe: Generieren Sie damit 5 Wörter.

$$abcb, ac, c, bcb, bbcbb, \ldots$$

Ableitung

Definition: Seien $\gamma_1, \gamma_2, \alpha, \beta \in (N \cup T)^*$ *und* $\alpha \to \beta \in P$, *dann bezeichnet* $\gamma_1\alpha\gamma_2 \Rightarrow \gamma_1\beta\gamma_2$ *die direkte* ***Ableitung*** des Wortes $\gamma_1\alpha\gamma_2$ *zu* $\gamma_1\beta\gamma_2$.

Seien $w_0, \ldots, w_n \in (N \cup T)^*$, *so dass* $w_0 \Rightarrow w_1 \Rightarrow \ldots \Rightarrow w_n$,

dann lässt sich w_n *aus* w_0 *ableiten und wir schreiben* $w_0 \overset{*}{\Rightarrow} w_n$.

Definition:

Eine Ableitung, bei der in jedem Ersetzungsschritt das äußerst linke (rechte) Nichtterminal-Zeichen ersetzt wird, heißt **Linksableitung** (bzw. **Rechtsableitung**).

Definition: Sei $G = (N, T, P, S)$, dann ist die von G erzeugte **Sprache** $L(G)$ die Menge aller Terminalwörter, die sich von S ableiten lassen:

$$L(G) = \{w \in T^* \mid S \overset{*}{\Rightarrow} w\}.$$

Beispiel

$G = (N, T, P, S)$, wobei

$$T = \{ a, b, c, \epsilon \}$$

$$N = \{ S, A, B \}$$

$$P = \{ S \rightarrow AB, A \rightarrow aA \mid \epsilon, B \rightarrow bBb \mid c \}$$

Kurzschreibweise für zwei Regeln desselben Nichtterminals.

Ein Wort $aabcb$ lässt sich wie folgt aus S ableiten:

$$S \Rightarrow AB \Rightarrow aAB \Rightarrow aaAB \Rightarrow aaB \Rightarrow aabBb \Rightarrow aabcb$$

Gibt es andere Ableitungen dieses Wortes?
Was ist die Sprache der Grammatik?

$$L(G) = \{a^n b^m c b^m, n \geq 0, m \geq 0\}$$

Beispiel

$$L = \{0^n 1^n | n \geq 0\} \cup \{1^n 0^n \mid n \geq 0\}$$

Um eine Grammatik dafür zu finden, bauen wir zuerst eine Grammatik für die linke Teilmenge. Offensichtlich benötigen wir eine rekursive Regel. Da auch das leere Wort zur linken Teilmenge gehört, lauten die Regeln:

$$S_1 \rightarrow 0S_1 1 | \epsilon$$

Analog für die rechte Teilmenge:

$$S_2 \rightarrow 1S_2 0 | \epsilon$$

Die Regeln für die gesamte Grammatik sind somit:

$$S \rightarrow S_1 | S_2$$
$$S_1 \rightarrow 0S_1 1 | \epsilon$$
$$S_2 \rightarrow 1S_2 0 | \epsilon$$

Aufgabe: Leiten Sie das Wort 0011 ab.

Tipps zu Grammatiken

„Ein Programm besteht aus mindestens einer aber beliebig vielen Funktionsdeklarationen.“

$$Program \rightarrow FuncDeclList$$

$$FuncDeclList \rightarrow FuncDecl \mid FuncDecl\ \ FuncDeclList$$

„Eine Funktionsdeklaration besteht aus einem Kopf gefolgt von beliebig vielen Anweisungen.“

$$FuncDecl \rightarrow Kopf\ AnweisungsList$$

$$AnweisungsList \rightarrow Anweisung\ AnweisungsList \mid \epsilon$$

Beispiel

$G = (N, T, P, S)$, wobei

$T = \{ if, then, else, (,), true, false, x, =, 0, 1 \}$
$N = \{ S, I, A, B, N \}$

$S \rightarrow I$
$S \rightarrow A$
$I \rightarrow if\ (\ B\ )\ then\ A\ else\ A$
$B \rightarrow true \mid false$
$A \rightarrow x = N$
$N \rightarrow 0$
$N \rightarrow 1$

Geben Sie die Sprache dieser Grammatik vollständig an!

$L(G) = \{ if\ (true)\ then\ x = 0\ else\ x = 0,$
$if\ (true)\ then\ x = 0\ else\ x = 1,$
$if\ (true)\ then\ x = 1else\ x = 0,$
$if\ (true)\ then\ x = 1else\ x = 1,$
$if\ (false)\ then\ x = 0\ else\ x = 0,$
$if\ (false)\ then\ x = 0\ else\ x = 1,$
$if\ (false)\ then\ x = 1\ else\ x = 0,$
$if\ (false)then\ x = 1\ else\ x = 1,$
$x = 0,\ x = 1 \}$

Reguläre Grammatiken

Eine kontextfreie Grammatik $G = (N, T, P, S)$ heißt **regulär**, wenn alle Produktionen entweder die Form

(i) A $\rightarrow$ wB oder A$\rightarrow$ w, mit $A, B \in N, w \in T^*$ (rechtsregulär)

oder

(ii) A $\rightarrow$ Bw oder A$\rightarrow$ w, mit $A, B \in N, w \in T^*$ (linksregulär)

besitzen.

Bei einer regulären Grammatik ist auf der rechten Seite einer Produktion höchstens ein Nichtterminalsymbol.

Gegenbeispiel:
$A \rightarrow aB, A \rightarrow Bc, B \rightarrow b$ ist nicht regulär, weil die erste Produktion rechtsregulär ist, die zweite aber linksregulär.

Reguläre Ausdrücke

- Sei Σ ein Alphabet. Ein regulärer Ausdruck r repräsentiert eine Sprache $\mathrm{L}(\mathrm{r}) \subseteq \Sigma^*$. Reguläre Ausdrücke sind definiert durch:
  - Für jedes $\mathbf{a} \in \boldsymbol{\Sigma}$ ist a ein regulärer Ausdruck und $L(a) = \{a\}$
  - $\boldsymbol{\epsilon}$ ist ein regulärer Ausdruck und $\mathrm{L}(\epsilon) = \{\epsilon\}$
  - $\emptyset$ ist ein regulärer Ausdruck und $\mathrm{L}(\emptyset) = \emptyset$
  - Seien r_1, r_2 reguläre Ausdrücke. Dann ist $(\boldsymbol{r_1}\ \boldsymbol{r_2})$ ein regulärer Ausdruck und $\mathrm{L}(r_1\ r_2) = L(r_1)\ L(r_2)$
  - Seien r_1, r_2 reguläre Ausdrücke. Dann ist $(\boldsymbol{r_1}|\ \boldsymbol{r_2})$ ein regulärer Ausdruck und $\mathrm{L}(r_1 \mid r_2) = L(r_1) \cup L(r_2)$
  - Sei r ein regulärer Ausdruck. Dann ist $\boldsymbol{r}^*$ ein regulärer Ausdruck und
    $$L(r^*) = L(r)^*$$
  - Sei r ein regulärer Ausdruck. Dann ist $\boldsymbol{r}^+$ ein regulärer Ausdruck und
    $$L(r^+) = L(r)^+$$
- Zwei reguläre Ausdrücke r und s sind äquivalent, wenn $L(r) = L(s)$.

Beispiel: Sprache eines regulären Ausdrucks

Gegeben: $r = (0|1)^*011$

Gesucht: $L(r)$

Herleitung:

$L((0|1)) = L(0) \cup L(1) = \{0\} \cup \{1\} = \{0,1\}$

$L((0|1)*) = L((0|1))^* = \{0,1\}^*$ (alle Binärzahlen)

$L(011) = \{011\}$

$\Rightarrow L(r) = L((0|1)011)) = \{0,1\}^*011$

Alle Binärzahlen, die auf 011 enden.

Reguläre Ausdrücke und Automaten

Satz:

Zu jedem regulären Ausdruck r gibt es einen nicht-deterministischen endlichen Automaten A, so dass $L(r) = L(A)$.

Die Sprache $L(r) = L(A)$ heißt **reguläre Sprache**.

Beweis:

Kapitel 3!

Ableitungsbaum

Definition:
Ein **Ableitungsbaum** ist ein Baum, der aus einer Ableitung eines Worts w bezüglich einer Grammatik G = (N, T, P, S) wie folgt konstruiert wird:

- Der Wurzelknoten wird mit dem Startsymbol S markiert
- Zu jeder in der Ableitung angewandten Regel $X \rightarrow x_1, \ldots, x_n$ werden dem mit X markierten Knoten im Baum, der das abgeleitete Nichtterminal repräsentiert, n neue, mit $x_1, \ldots, x_n$markierte Knoten als Nachfolgeknoten zugeordnet.

Die Blätter ergeben von links nach rechts angeordnet das abgeleitete Wort w.

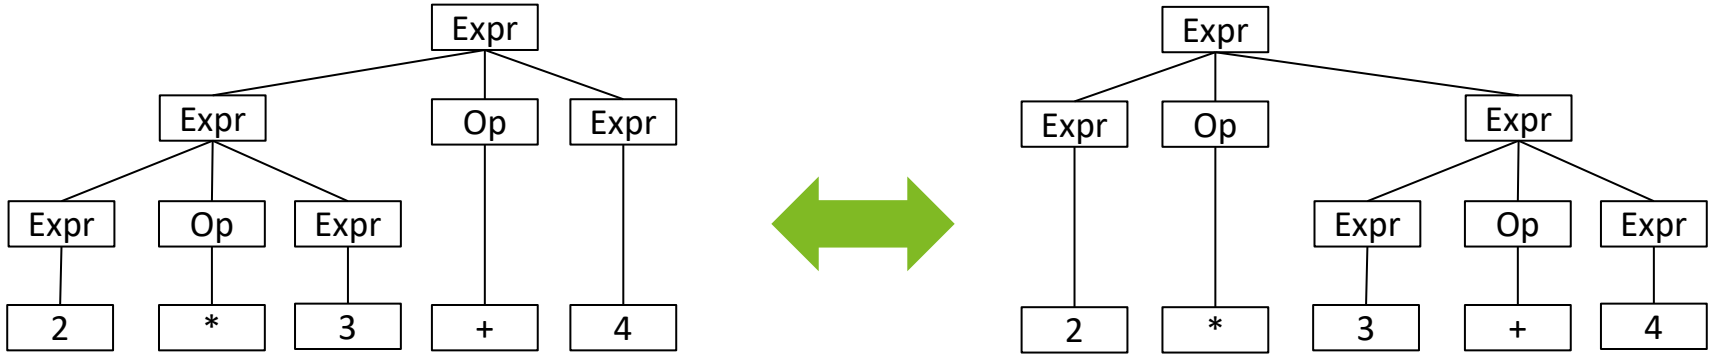
Mehrdeutige Grammatiken

Beispiel:

Expr -> Expr Op Expr |
‘(‘ Expr ‘)’ |
INTLIT |
IDENTIFIER

Op -> ‘+’ | ‘-’ | ‘*’ | ’/’

Eingabetext: 2*3+4



Definition: Eine Grammatik heißt mehrdeutig, wenn es ein Wort mit zwei verschiedenen Linksableitungen gibt.

Schema für die Definition einer Grammatik für Ausdrücke

- Eine Regel $X \rightarrow X\alpha$ heißt **linksrekursiv**, $X \rightarrow \alpha X$ **rechtsrekursiv**.
- Jeder Präzedenzstufe wird ein eigenes Nichtterminal zugeordnet.
- Ein **linksassoziativer** Operator Op der Stufe i wird durch linksrekursive Regel

  $Expr_i$ -> $Expr_i$ Op $Expr_{i+1}$ abgebildet.
- Ein **rechtsassoziativer** Operator Op der Stufe i wird durch rechtsrekursive Regel

  $Expr_i$ -> $Expr_{i+1}$ Op $Expr_i$ abgebildet.
- Ein **nichtassoziativer** Operator Op der Stufe i wird durch Regel

  $Expr_i$ -> $Expr_{i+1}$ Op $Expr_{i+1}$ abgebildet.

Beispiel (Grammatik d) oben) für die linksassoziativen Operatoren + und *.

$Expr_1$ -> $Expr_1$ + $Expr_2$ | $Expr_2$
$Expr_2$ -> $Expr_2$ * $Expr_3$ | $Expr_3$
$Expr_3$ -> ($Expr_1$) | x

Grammatiktransformationen

- **Elimination von Linksrekursion**

  $X \rightarrow X\,\alpha \mid \beta$

  kann man umschreiben in:

  $X \rightarrow \beta\,X'$

  $X' \rightarrow \alpha\,X' \mid \varepsilon$

- **Linksfaktorisierung**

  Wenn zwei rechte Seiten für ein Nichtterminal X mit dem gleichen Wort u der Länge k beginnen ($X \rightarrow u\,\alpha \mid u\,\beta$), dann ist mit einer Vorausschau (‚lookahead') der Länge k die eindeutige Auswahl einer Regel nicht möglich.
  Ersetze dann die Regeln durch:

  $X \rightarrow u\,X'$,

  $X' \rightarrow \alpha \mid \beta$

Reguläre Grammatiken

Satz: Jede reguläre Grammatik ist kontextfrei.

Beweis: siehe Definitionen.

Satz: Sei $G = (N, T, P, S)$ eine kontextfreie Grammatik mit $|T| = 1$, dann ist $\mathrm{L}(G)$ auch regulär.

Satz: Die Klasse aller kontextfreien Sprachen über einem Alphabet mit zwei oder mehr Zeichen ($|T| \geq 2$) CFL_T ist eine echte Obermenge der Klasse aller regulärer Sprachen REG_T.

Beweis: Der erste Satz zeigt, dass $REG_T \subseteq CFL_T$. Im vorigen Kapitel hatten wir bewiesen, dass die Sprache $L = \{a^n b^n \mid n \geq 0\}$ nicht regulär ist. Sie ist aber kontextfrei, da sie von der Grammatik $S \rightarrow aSb|\epsilon$ erzeugt wird. Also gilt: $REG_T \subset CFL_T$.

Chomsky-Normalform

Definition: Eine kontext-freie Grammatik ist in Chomsky-Normalform, wenn jede Regel in der Form

(i) $A \to BC$ oder
(ii) $A \to a$ ist,
wobei B und C nicht das Startsymbol sind.
Zusätzlich ist die Produktion $S \to \epsilon$ zugelassen, wenn S das Startsymbol ist.

Satz: Jede kontext-freie Sprache wird durch eine Grammatik in Chomsky-Normalform generiert.

Beweis: Sipser, p. 109ff.