Grammatiktransformationen

- **Elimination von Linksrekursion**

  $X \rightarrow X\ \alpha \mid \beta$

  kann man umschreiben in:

  $X \rightarrow \beta\ X'$

  $X' \rightarrow \alpha\ X' \mid \varepsilon$

- **Linksfaktorisierung**

  Wenn zwei rechte Seiten für ein Nichtterminal X mit dem gleichen Wort u der Länge k beginnen ($X \rightarrow u\,\alpha \mid u\,\beta$), dann ist mit einer Vorausschau (‚lookahead') der Länge k die eindeutige Auswahl einer Regel nicht möglich.
  Ersetze dann die Regeln durch:

  $X \rightarrow u\,X'$,

  $X' \rightarrow \alpha \mid \beta$

Reguläre Grammatiken

Satz: Jede reguläre Grammatik ist kontextfrei.

Beweis: siehe Definitionen.

Satz: Sei $G = (N, T, P, S)$ eine kontextfreie Grammatik mit $|T| = 1$, dann ist $\mathrm{L}(G)$ auch regulär.

Satz: Die Klasse aller kontextfreien Sprachen über einem Alphabet mit zwei oder mehr Zeichen ($|T| \geq 2$) CFL_T ist eine echte Obermenge der Klasse aller regulärer Sprachen REG_T.

Beweis: Der erste Satz zeigt, dass $REG_T \subseteq CFL_T$. Im vorigen Kapitel hatten wir bewiesen, dass die Sprache $L = \{a^n b^n \mid n \geq 0\}$ nicht regulär ist. Sie ist aber kontextfrei, da sie von der Grammatik $S \rightarrow aSb|\epsilon$ erzeugt wird. Also gilt: $REG_T \subset CFL_T$.

Chomsky-Normalform

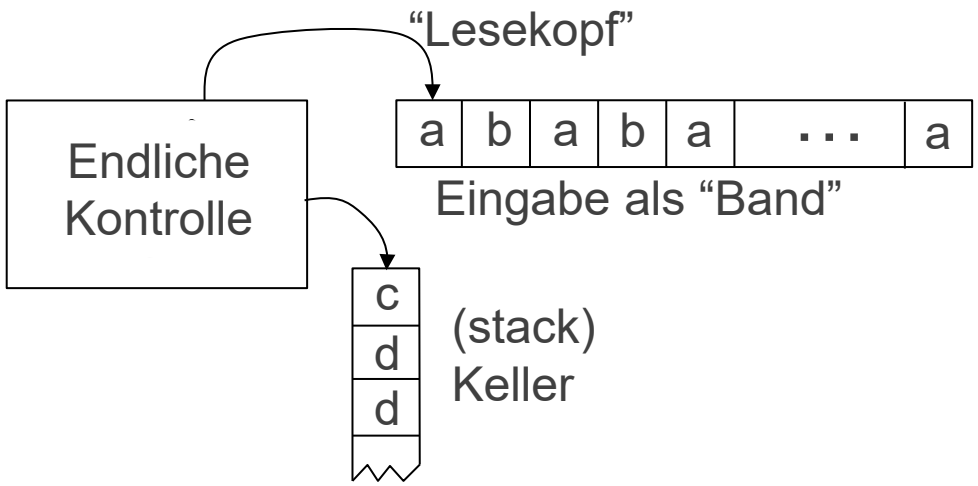
Definition: Eine kontext-freie Grammatik ist in Chomsky-Normalform, wenn jede Regel in der Form

(i) $A \to BC$ oder
(ii) $A \to a$ ist,
wobei B und C nicht das Startsymbol sind.
Zusätzlich ist die Produktion $S \to \epsilon$ zugelassen, wenn S das Startsymbol ist.

Satz: Jede kontext-freie Sprache wird durch eine Grammatik in Chomsky-Normalform generiert.

Beweis: Sipser, p. 109ff.

Kellerautomaten („Pushdown Automata“)

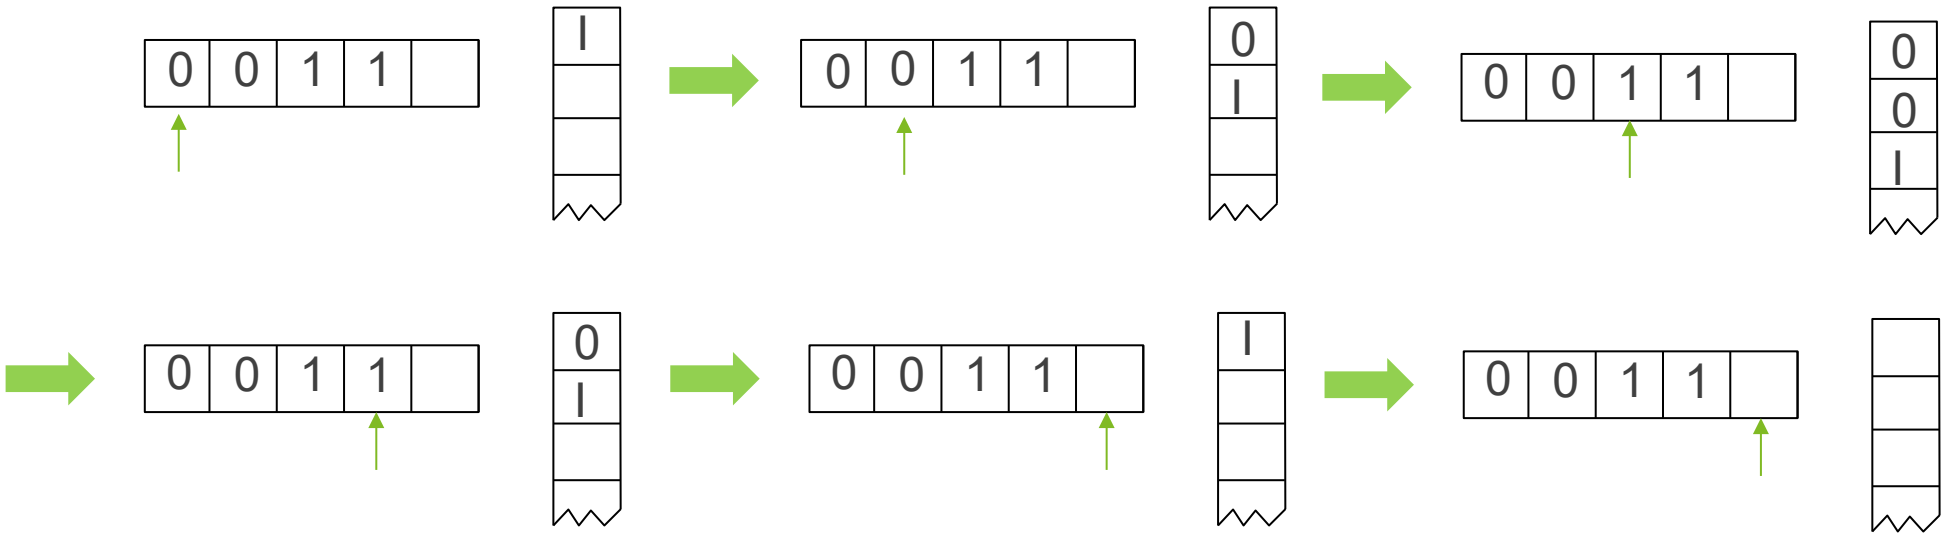


Kellerautomaten können mit *push* auf den Stack schreiben und mit *pop* lesen.

Beispiel

$L = \{0^k 1^k \mid k \geq 1\}$ kann durch einen Kellerautomaten erkannt werden, der

1. Zu Beginn ein Startsymbol I im Keller steht
2. Wenn er eine *0* liest, diese auf den Keller schreibt.
3. Wenn er eine 1 liest, ein pop durchführt.
4. Wenn das Eingabewort leer und im Keller I steht, ein pop durchführt
5. Der Automat akzeptiert das Eingabewort, wenn die Eingabe endet und er in einem Endzustand ist.



Definition Kellerautomat

Definition: Ein (nichtdeterministischer) Kellerautomat ist ein 7-Tupel $(Q, \Sigma, \Gamma, I, \delta, q_0, F)$, wobei Q, Σ, Γ, F endliche Mengen sind und

(i) Q ist die Menge der Zustände

(ii) Σ ist das Eingabealphabet

(iii) Γ ist das Kelleralphabet

(iv) $I \in \Gamma$ ist das Kellervorbelegungszeichen

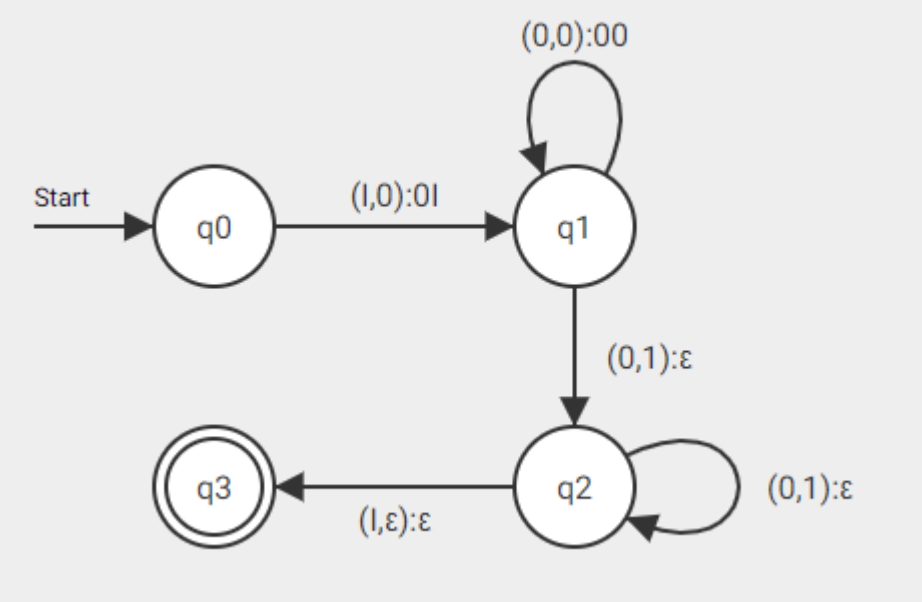
(v) $\delta: Q \times \Sigma_\epsilon \times \Gamma \rightarrow \wp(Q \times \Gamma_\epsilon^*)$ ist die Überführungsfunktion

(vi) $q_0 \in Q$ ist der Startzustand

(vii) $F \subseteq Q$ ist die Menge der akzeptierenden Zustände.

Ein Kellerautomat beginnt mit dem Symbol I im Keller und im Startzustand.
Der Automat akzeptiert, wenn es eine Folge von Überführungen gibt, die bei leerem Eingabeband in einem Endzustand endet.

Beispiel 1



$(a, b): c$ bedeutet: Pop a, lese b, push c
(Oberstes Kellersymbol a wird durch c ersetzt)

$(a, \epsilon): c$ heißt dann: Pop a, lese nichts, push c

$(a, b): \epsilon$ heißt: Pop a, lese b, push nichts

Zustand	Wort	Keller
q0	0011	I
q1	011	$0I$
q1	11	$00I$
q2	1	$0I$
q2	ϵ	I
q3		

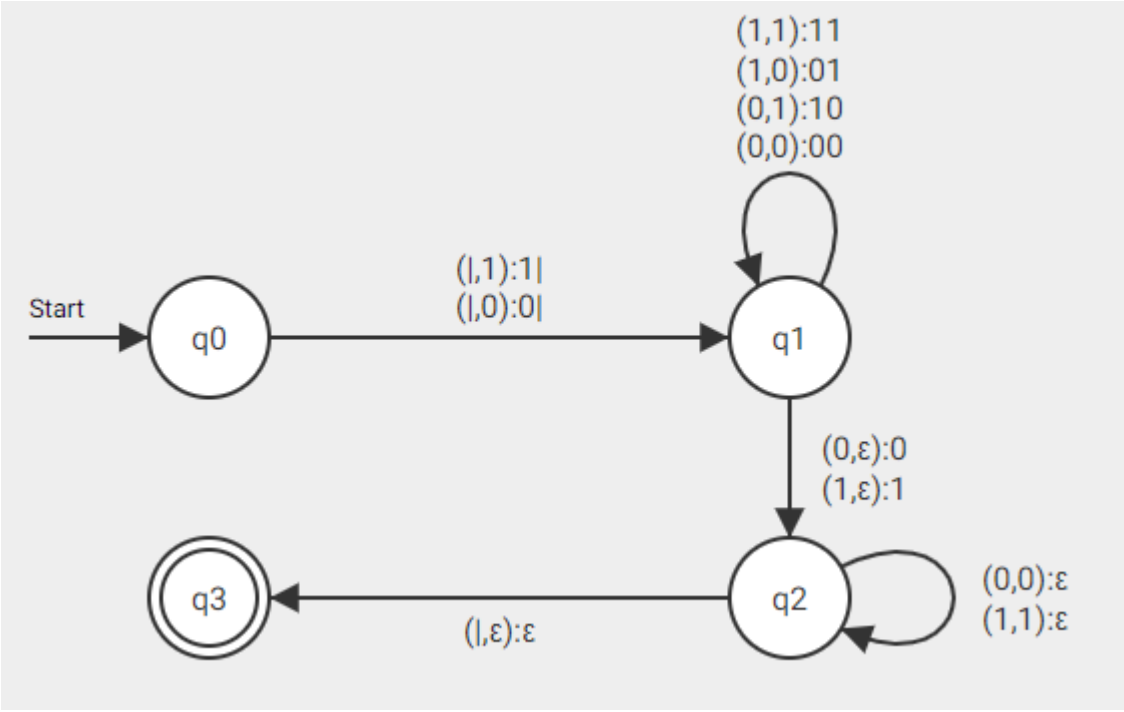
Welche Sprache erkennt der Automat?

$L = \{0^k 1^k \mid k \geq 1\}$

Beispiel 2

Wir wollen die Sprache $\{w\, w^r | w \in \{0,1\}^*\}$ erkennen.

Der Automat muss dazu alle Zeichen des ersten Wortes push'en, dann „raten", wo die Mitte des gesamten Wortes ist und dann das zweite Wort einlesen und prüfen, dass die Zeichen mit dem jeweils obersten Stacksymbol übereinstimmen. Offensichtlich muss der Automat nichtdeterministisch sein.



Zustand	Wort	Keller
q0	0110	
q1	0110	I
q1	110	0I
q1	10	10I
q2	10	10I
q2	0	0I
q2		I
q3		

Äquivalenz Kellerautomat und kontextfreie Sprachen (a)

Satz: Eine Sprache ist kontextfrei genau dann, wenn sie durch einen Kellerautomaten akzeptiert wird.

Beweisidee: a) „⇒ "
Wenn die Sprache kontextfrei ist, dann wird sie von einer kontextfreien Grammatik erzeugt.

1. Wir pushen $ und das Startsymbol der Grammatik.
2. Wiederhole
   a) Wenn das oberste Symbol auf dem Stack ein Nichtterminal A ist, dann wähle (nichtdeterministisch) eine Regel $A \rightarrow \alpha$ aus und lege alle Symbole von α auf dem Stack ab.
   b) Wenn das oberste Symbol auf dem Stack ein Terminalsymbol a ist und mit dem nächsten Eingabezeichen übereinstimmt, lösche a vom Stack. Bei Nichtübereinstimmung verwerfe diesen Zweig des Nichtdeterminismus.
3. Wenn das oberste Symbol auf dem Stack $ ist und das Eingabeband leer, akzeptiere.

Äquivalenz Kellerautomat und kontextfreie Sprachen (b)

b) Wenn ein Kellerautomat eine Sprache akzeptiert, ist sie kontextfrei.

Beweisidee:

> Basierend auf den Zuständen des Automaten wird eine Grammatik G konstruiert:
> Für jedes Paar p, q von Zuständen wird ein Nichtterminal A_{pq} erzeugt.
> A_{pq} generiert alle Worte, die den Automaten von p nach q bringen und dabei den Stack nicht verändern.

Der formale Beweis findet sich bei Sipser auf den Seiten 121-124.

Kontextfreie und regulären Sprachen

Korollar: Jede reguläre Sprache ist kontextfrei.

Beweis: Ein endlicher Automat ist ein Kellerautomat, der seinen Stack nicht verwendet.

Korollar: Die Klasse der kontextfreien Sprachen CFL ist abgeschlossen unter $\cup, *$ und Konkatenation.

Beweis:

a) Seien $G_1 = (N_1, T_1, P_1, S_1)$ und $G_2 = (N_2, T_2, P_2, S_2)$ kontextfrei und $N_1 \cap N_2 = \emptyset$
Dann ist $G = (N_1 \cup N_2, T_1 \cup T_2, P_1 \cup P_2 \cup \{S \to S_1 | S_2\},\ S)$ kontextfrei und erkennt $L(G_1) \cup L(G_2)$.

b) Sei $G_1 = (N_1, T_1, P_1, S_1)$ kontextfrei.
Dann ist $G = (N_1, T_1, P_1 \cup \{S \to SS \mid S_1 | \epsilon\},\ S)$ kontextfrei und generiert $L(G_1)^*$.

c) Geht analog.

Reguläre Grammatiken -> reguläre Sprachen

Satz: Sei $G = (N, T, P, S)$ eine reguläre Grammatik, dann ist $L(G)$ eine reguläre Sprache.

Beweis: Wir geben ein Verfahren an, mit dem man aus der Grammatik einen NEA $A = (N, T, \delta, S, F)$ konstruiert. Die Zustände sind also die Nichtterminale.

(i) ObdA nehmen wir an, dass die Grammatik rechtsregulär ist. Dann können wir alle Produktionen umschreiben, so dass alle Produktionen in der Form $X \to aY$ oder $X \to \epsilon$ vorliegen mit $a \in T$ (rechtslineare Grammatik).

(ii) Wenn es eine Produktion X$\to \epsilon$ gibt, dann ist X ein Endzustand.

(iii) Wenn es eine Produktion X$\to a$ gibt, dann füge einen Endzustand q_f und einen Übergang $(X, a\, q_f)$ hinzu.

(iv) Wenn es eine Produktion $B \to aC$ gibt, dann gehört (B, a, C) zu δ.

Dieser Automat erkennt genau alle Wörter aus $L(G)$ und somit ist $L(G)$ eine reguläre Sprache.

Satz: Sei $A = (\Sigma, S, \delta, q_0, F)$ ein endlicher Automat, dann existiert eine Grammatik $G = (S, \Sigma, P, q_0)$ mit $L(A) = L(G)$.

Beweis: Umkehrung der Vorgehensweise im vorigen Beweis.

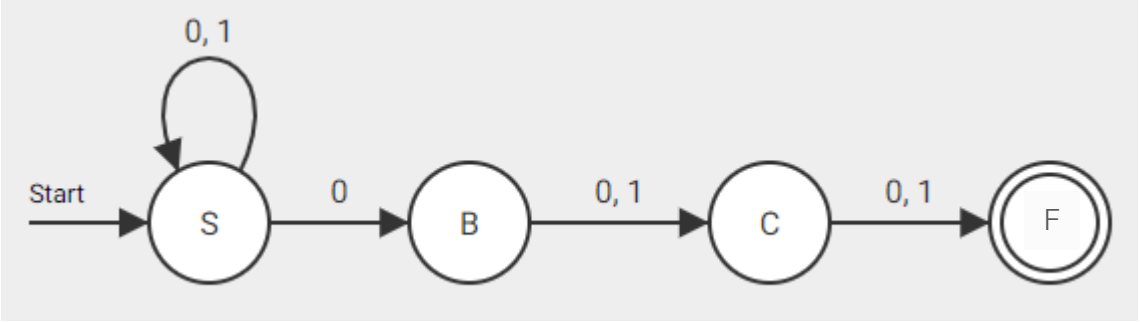
Beispiel

S → 0S | 1S | 0B

B → 0C | 1C

C → 0F | 1F

F → ϵ

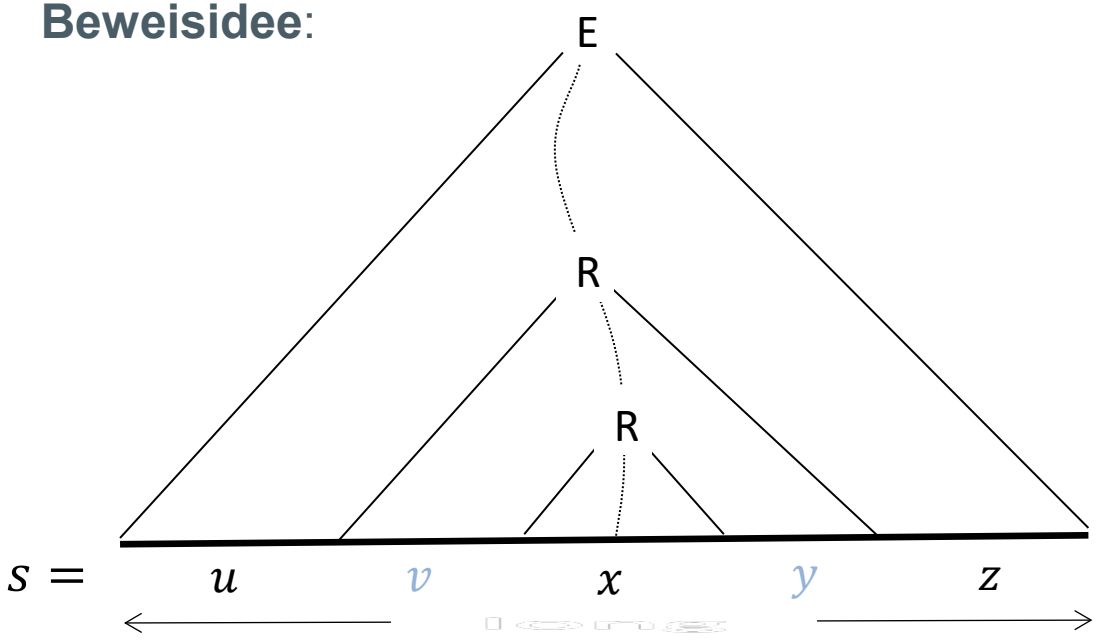


Pumping Lemma für kontextfreie Sprachen

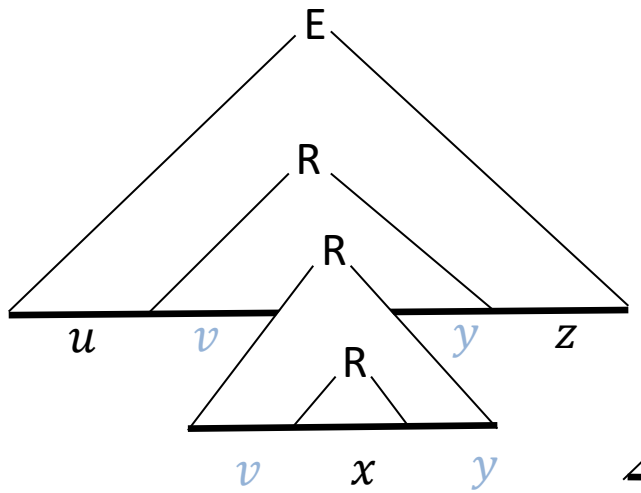
Satz: Für jede kontextfreie Sprache L gibt es ein p, sodass wenn $s \in L$ und $|s| \geq p$, dann ist $s = uvxyz$ mit

1) $uv^ixy^iz \in \mathrm{L}$ für alle $i \geq 0$
2) $vy \neq \varepsilon$
3) $|vxy| \leq p$

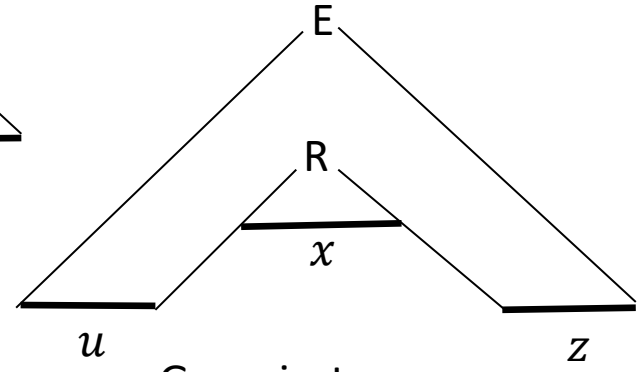
Beweisidee:



Langes Wort $s \rightarrow$
hoher Ableitungsbaum



Generiert $uvvxyyz$
$= uv^2xy^2z$



Generiert uxz
$= uv^0xy^0z$

Beispiel

Behauptung: $L = \{ww | w \in \{0,1\}^*\}$ ist nicht kontextfrei.

Beweis: Wir nehmen an, dass L kontextfrei ist.

Wähle $s = 0^p 1^p 0^p 1^p$.

s= 0…01…10…01…1

Wenn $vy = \epsilon$ wäre, wäre $s = uxz$ und mindestens einer der drei Teile müsste 0‘en und 1‘en enthalten.

Beim Aufpumpen würde aber ein Wort entstehen, bei dem die 4 Teile nicht gleichlang sein können.

Da $|vxy| \leq p$, kann vxy sich nicht mit zwei Blöcken von 0‘en oder 1‘en überschneiden.

a) $vxy = 0^p$, dann enthält uv^2xy^2z einen Block mit p Nullen und einen mit mindestens $p + 2$.

b) Dito für $vxy = 1^p$

c) $\mathrm{u} = 0^{\mathrm{p}-\mathrm{a}}$, $vxy = 0^a 1^b, z = 1^{p-b} 0^p 1^p$, wobei $a + b \leq p$,

Egal wie man v, x, y wählt, ist das aufgepumpte Wort nicht mehr in L.

d) Alle anderen Fälle analog.

Deterministische Kellerautomaten

Definition: Ein deterministischer Kellerautomat ist ein 6-Tupel $(Q, \Sigma, \Gamma, I, \delta, q_0, F)$, wobei Q, Σ, Γ, F endliche Mengen sind und

(i) Q ist die Menge der Zustände

(ii) Σ ist das Eingabealphabet

(iii) Γ ist das Kelleralphabet

(iv) $I \in \Gamma$ ist das Kellervorbelegungssymbol

(v) $\delta: Q \times \Sigma_\epsilon \times \Gamma_\epsilon \to (Q \times \Gamma\ ) \cup \{\emptyset\}$ ist die Überführungsfunktion

(vi) $q_0 \in Q$ ist der Startzustand

(vii) $F \subseteq Q$ ist die Menge der akzeptierenden Zustände.

Die Überführungsfunktion δ muss die folgende Bedingung erfüllen:

Für alle $q \in \mathrm{Q}, a \in (\Sigma \cup \epsilon), x \in \Gamma$ gilt:

i. $|\,\delta(q, a, x)| \leq 1$

ii. Wenn $\delta(q, \epsilon, x) \neq \emptyset$, dann muss für alle $\mathrm{a} \in \Sigma$ $\delta(q, a, x) = \emptyset$ sein.

DCFL

Definition: Die Sprache, die von einem deterministischen Kellerautomaten erkannt wird, heißt deterministisch kontextfreie Sprache.

Die Menge aller kontextfreien Sprachen wird mit DCFL abgekürzt.

Backus-Naur Form (BNF)

- Wurde von John Backus und Peter Naur für die Beschreibung von ALGOL-60 entwickelt.
- BNF ist eine andere Schreibweise von kontextfreien Grammatiken:
  - Nichtterminalsymbole werden in spitze Klammern < > eingeschlossen.
  - Statt des Pfeils → wird ::= verwendet.
  - Alternativen werden auch durch senkrechte Striche | voneinander getrennt.
  - Wiederholungen werden durch Rekursion abgebildet (wie bei kontextfreien Grammatiken auch).

Beispiel:

<digit> ::= 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9

Erweiterte Backus-Naur Form (EBNF)

- Wurde von Niklaus Wirth für die Beschreibung von Pascal 1971 entwickelt.
- Statt ::= wird ein einfaches Gleichheitszeichen benutzt.
- Das Ende einer Regel wird explizit kenntlich gemacht (bei Wirth mit einem Punkt, aber oft auch mit einem Semikolon).
- Terminalsymbole werden in doppelte Anführungszeichen " " gesetzt.
- Die spitzen Klammern bei Nichtterminalsymbolen entfallen.
- Die rechten Seiten der Regeln sind nun Ausdrücke, die wie folgt zusammengesetzt sein können:
  - | trennt Alternativen.
  - Zusätzlich zur BNF gibt es die Möglichkeit, in eckigen Klammern [ ] optionale Elemente anzugeben.
  - Durch geschweifte Klammern { } können Wiederholungen (kein Mal oder mehrmals) angegeben werden.
  - Runde Klammern ( ) können zur Gruppierung genutzt werden.

EBNF Beispiel

EBNF:

IfAnweisung ="if" BoolescherAusdruck "then" Anweisung
["else" Anweisung]

Als kontextfreie Grammatik:

$$IfAnweisung \rightarrow if\ BoolescherAusdruck\ then\ Anweisung$$
$$\mid if\ BoolescherAusdruck\ then\ Anweisung\ \text{else Anweisung}$$

Tipp: Wenn Sie eine Grammatik aufstellen sollen, beginnen Sie mit einer EBNF und formen diese um.